

Cours de Statistique Descriptive S₂

La concentration :

L'objectif de la concentration est de **mesurer les inégalités dans la répartition d'une variable à l'intérieur d'une population**. Quantitatives continues représentant une valeur positive cumulée. Concentration d'une distribution. Concentration forte: lorsque cette différence est grande par rapport à l'étendue.

APPLICATION :

On considère une série statistique continue et positive, par exemple la série des salaires bruts mensuels versés dans une entreprise l'année dernière (250 salariés étudiés). Les résultats sont regroupés dans le tableau suivant :

Classe des salaires mensuels bruts en euros	Centre de la classe	Effectif correspondant	Valeurs globales	Valeurs globales relative	Valeurs globales cumulées	Valeurs globales relatives cumulées croissantes
[1200 ; 1600[		25				
[1600 ; 2000[		32				
[2000 ; 2400[		54				
[2400 ; 2800[		60				
[2800 ; 3200[		44				
[3200 ; 3600[		19				
[3600 ; 4000[		10				
[4000 ; 4600[		4				
[4600 ; 5400[		2				
Total éventuellement		250				

Les valeurs globales : Ce sont les quantités $n_i x_i$.

Exemple : les salariés qui ont un salaire dont le montant est compris entre 2000 € et 2400 € **représentent ensemble, globalement**, une masse salariale égale à : 118800 €

Le total de la masse salariale est égal à : $\sum n_i x_i$.

Dans l'exemple, la masse salariale totale est égale à : 629200 €

Valeurs globales relatives

$$q_i = \frac{n_i x_i}{\sum n_i x_i}$$

Ce sont les quantités
compris entre 0 et 1.

qui s'expriment par un nombre

Exemple : les salariés qui ont un salaire dont le montant est compris entre 3200 € et 3600 € **représentent ensemble, globalement**, un pourcentage de la masse salariale totale égal à : 10,27 %.

Valeurs globales relatives cumulées croissantes

$$Q_i = q_i \square = \frac{n_i x_i \square}{\sum n_i x_i}$$

Ce sont les quantités
compris entre 0 et 1.

, qui s'expriment aussi par un nombre

Exemple : les salariés qui ont un salaire dont le montant est inférieur à 3600 € **représentent ensemble, globalement**, un pourcentage de la masse salariale totale égale à : 89,63 %.

ENSEIGNANT : Mohamed vall Zein

Mesure de la concentration par l'indicateur Ecart Médiale-Médiane :

La détermination de cet indicateur nécessite au préalable la connaissance de la notion médiale.

La médiale :

C'est une médiane calculée par rapport aux valeurs globales relatives.
Méthode de calcul

On repère quelle est **la première classe** pour laquelle les valeurs globales relatives cumulées croissantes dépassent pour la **première fois 0,5** (ce qui représente la moitié de la masse salariale totale dans l'exemple). C'est la classe médiale.

On cherche **la valeur médiale** par interpolation linéaire, **à l'intérieur de cette classe médiale**.

*** Etude de la différence entre la médiale (M1) et la médiane (Me) :**

L'étude de l'écart entre M1 et Me ou ΔM va nous conduire à se prononcer sur le degré de concentration d'une variable statistique dans une série statistique.

* Plus l'écart entre M1 et Me est important, plus la concentration est importante.

* Plus ΔM est réduit, plus la concentration est faible

Pour juger le degré de concentration d'un phénomène, on compare ΔM avec le domaine de variation de la variable statistique (étendue).

ENSEIGNANT : Mohamed vall Zein

Exemple de détermination de la médiale :

La classe médiale est [2400 ; 2800[.

Par interpolation linéaire, on trouve l'équation :

$$\frac{Mle - 2400}{0,5 - 0,336} = \frac{2800 - 2400}{0,584 - 0,336}$$

$$Mle = 2400 + 0,164 \times \frac{400}{0,248}$$

$$Mle = 2664,5 \text{ € arrondi à } 2664 \text{ €}$$

Interprétation :

Les salariés qui ont un salaire inférieur à 2664 € représentent ensemble la moitié de la masse salariale globale. Evidemment, ceux qui gagnent plus de 2664 € représentent ensemble l'autre moitié de la masse salariale globale.

Retenir :

La médiale est une *valeur du caractère*.

Remarque :

La médiale est toujours supérieure à la médiane.

La courbe de concentration :


Cette courbe aussi appelée courbe de LORENZ, ou de GINI, sert à décrire la concentration des revenus (des salaires) dans une population.

Sur l'axe des abscisses, on porte les fréquences cumulées croissantes F_i .

Sur l'axe des ordonnées, on porte les valeurs globales relatives cumulées croissantes Q_i .

ENSEIGNANT : Mohamed vall Zein

LE GRAPHIQUE DE LA COURBE DE LORENZ



ENSEIGNANT : Mohamed vall Zein

Interprétation

Chaque point de la courbe peut s'interpréter ainsi : un pourcentage F_i de la population représente un pourcentage Q_i du total des salaires versés.

Par exemple, 86 % des salariés se partagent 79,4 % du montant total des salaires versés.

Plus la courbe s'éloigne de la diagonale, plus la concentration n'est forte, c'est à dire la répartition inégalitaire.

La diagonale du carré représente l'équirépartition, tout le monde gagne le même salaire.

Cette courbe permet de visualiser la répartition des revenus, des patrimoines, des terres agricoles...et donc permet de comprendre l'économie, voire la politique...

L'aire de concentration

On appelle **aire de concentration** l'aire S qui est comprise entre la courbe de concentration et la diagonale du carré. Sur la figure du cours cette aire est coloriée en jaune.




Nous voyons que, plus la concentration n'est importante, plus cette aire l'est aussi.

L'indice de concentration de Gini se calcul par la formule suivante :


$$IG = 1 - \sum f_i (Q_i + Q_{i-1})$$

من المقاييس الهامة والأكثر شيوعاً في قياس عدالة توزيع الدخل القومي، (نسبة للعالم كورا دو جيني) عامل جيني تعتمد فكرته على منحنى لورنز، يمتاز معامل جيني بأنه يعطي قياساً رقمياً لعدالة التوزيع، وتتلخص فكرته بحساب المساحة المحصورة بين منحنى لورنز وبين خط المساواة (الخط القطري الواصل بين نقطة الأصل والنقطة (1,1) في الرسم البياني) وضرب هذه المساحة بـ 2، وذلك لأن مساحة المثلث المحصورة بين خط التساوي والإحداثيتين الأفقي والعمودي تساوي 0.5، لذا فإن معامل جيني ينحصر بين الصفر والواحد، حيث يكون صفراً عندما ينطبق منحنى لورنز على خط التساوي وتكون المساحة مساوية للصفر ويكون عندها توزيع الدخل متساوياً لجميع أفراد المجتمع (التوزيع الأمثل للدخل)، بينما يكون معامل جيني مساوياً للواحد عندما ينطبق منحنى لورنز على الخط الأفقي والخط العمودي وتكون المساحة بين خط التساوي ومنحنى لورنز تساوي 0.5 وتكون عندها قيمة معامل جيني مساوية للواحد الصحيح وفي هذه الحالة يكون توزيع الدخل في أسوأ أحواله، أي أنه كلما كانت قيمة معامل جيني صغيرة كانت عدالة توزيع الدخل أفضل



Le coefficient de Gini, ou indice de Gini, est une mesure [statistique](#) permettant de rendre compte de la répartition d'une variable (salaire, revenus, patrimoine) au sein d'une population. Avec plus de précision, il mesure le niveau d'inégalité de la répartition d'une variable dans la population.

Ce coefficient est typiquement utilisé pour mesurer l'[inégalité des revenus](#) dans un pays. Il a été développé par le statisticien italien [Corrado Gini](#). Le [coefficient](#) de Gini est un nombre variant de 0 à 1, où 0 signifie l'[égalité](#) parfaite où tous les revenus de toutes les personnes sont égaux au cours d'une période de temps donnée, et 1 signifie une inégalité parfaite (une seule personne dispose de tout le revenu national et toutes les autres n'ont aucun sou).



La courbe de Lorenz :

- **Axe horizontal :** % cumulé de la population (individus classés du plus pauvre au plus riche)
- **Axe vertical :** % cumulé des revenus perçus par chaque % cumulé de la population.
- **Ligne à 45 degrés :** courbe de Lorenz en cas d'égalité parfaite.
- **La distance globale entre la ligne des 45 degrés et la courbe de Lorenz** est indicative du degré d'inégalité présent dans la population.

Chapitre 2: Corrélation

1. Corrélation entre deux variables

Jusqu'à présent, nous nous sommes intéressés à des questions du type:

- quelle est la taille moyenne des garçons belge âgés d'une vingtaine d'années ?
- quel pourcentage de voix un parti politique recueillera-t-il aux prochaines élections ?
- quelle fraction des barres métalliques produites par une usine sera-t-elle rejetée par le client ?
- le poids moyen des pains produits dans une boulangerie est-il supérieur à 800 grammes ?

Dans toutes ces questions, nous étudions le comportement statistique d'une seule variable: **taille, efficacité du médicament, pourcentage de voix, longueur des barres, poids des pains.**

Il existe cependant toute une gamme de problèmes statistiques où l'on s'intéresse à la **relation entre plusieurs variables.**

Exemples:

- les individus les plus grands sont-ils les plus lourds ?
- le revenu d'une famille a-t-il une influence sur les résultats scolaires des enfants ?
 - y a-t-il une relation entre le tabagisme et les cancers du poumon ?
 - le rendement en céréales dépend-il de la quantité d'engrais utilisée ?
- la productivité d'une entreprise est-elle liée au salaire des ouvriers ou employés ?

Dans ces questions, nous désirons savoir si le comportement d'une variable est influencé par la valeur d'une autre variable:

taille	↔	poids
tabagisme	↔	cancer
revenu	↔	résultats
rendement	↔	engrais

La relation peut être **causale** ou non.

Pour étudier les **relations** ou **corrélations** entre deux variables statistiques, on peut les porter sur un graphique.

Exemple:


Relation entre la taille et le poids des individus.

Pour chaque individu de l'échantillon, on porte sur un graphique:


- sa taille en abscisse
- son poids en ordonnée

chaque individu est donc, dans ce graphique, **représenté** par un point (**point représentatif**).

Soit un individu mesurant 172 cm et pesant 66 kg:



Dans le graphe, il y aura donc autant de points qu'il y a d'individus dans l'échantillon.



Relation entre le poids et la taille dans un échantillon de 30 individus.


On peut (par la pensée ou réellement) tracer une droite qui passe au mieux par ces points (au milieu du "nuage" de points).

Si cette droite "**monte**", on dira qu'il y a **corrélation positive** entre les deux variables.


Si elle "descend", c'est une **corrélacion négative**.

Si elle est "horizontale", ou si on ne peut pas décider, c'est qu'il y a **absence de corrélation**.


Corrélation positive:



Corrélation négative:




Absence de corrélation:




La **qualité** de la corrélation entre deux variables peut se mesurer par la **dispersion** des points autour de la relation moyenne.


Corrélation parfaite:



Bonne corrélation (corrélation forte):




Mauvaise corrélation (corrélation faible):



Exemples:


- Corrélation entre le poids et la taille pour les garçons de 2^{ème} candidature communication (1998).



On constate une augmentation du poids avec la taille (**corrélation positive**): les garçons les plus grands sont généralement les plus lourds.

Mais la dispersion des points est assez grande: **la corrélation est assez faible**.

- Corrélation entre le poids et la taille pour les filles de 2^{ème} candidature communication (1998).



On ne constate pas de relation entre du poids et la taille (**absence de corrélation**): le poids des filles est pratiquement indépendant de leur taille.


(les filles les plus grandes sont donc les plus minces)

2. Méthode des moindres carrés

Si on se contente de tracer à main levée la droite qui "passe au mieux" par les points représentatifs, différentes personnes vont obtenir des résultats différents.

Il existe une méthode mathématique pour déterminer la "meilleure" droite: c'est la **méthode des moindres carrés**.

Elle consiste, dans sa version la plus simple, à trouver la droite qui minimise les carrés des écarts des points représentatifs à cette droite.



Trouver la droite telle que la somme des carrés des écarts $d_1, d_2, \dots$ soit minimale:

$$\sum d^2 = \text{minimum}$$

Soit:

$$Y = a.X + b$$

l'équation de la droite cherchée (**droite de régression**).

Les coefficients a et b peuvent être calculés à partir des formules suivantes:

Pente:

$$a = \frac{(X_1 - \bar{X}).(Y_1 - \bar{Y}) + (X_2 - \bar{X}).(Y_2 - \bar{Y}) + \dots + (X_n - \bar{X}).(Y_n - \bar{Y})}{(X_1 - \bar{X})^2 + (X_2 - \bar{X})^2 + \dots + (X_n - \bar{X})^2}$$

ou

$$a = \frac{\sum (X - \bar{X}).(Y - \bar{Y})}{\sum (X - \bar{X})^2}$$

Ordonnée à l'origine:

$$b = \bar{Y} - a.\bar{X}$$

Rappels:

$$\bar{X} = \frac{1}{n} \sum X$$

$$\bar{Y} = \frac{1}{n} \sum Y$$

3. Coefficient de corrélation

Le signe de la pente a donne le sens de la corrélation, mais pas sa qualité.

$a > 0$ corrélation positive

$a < 0$ corrélation négative

$a = 0$ pas de corrélation

La **qualité** de la corrélation peut être mesurée par un **coefficient de corrélation** r .

$$r = \frac{\sum (X - \bar{X}).(Y - \bar{Y})}{\sqrt{\sum (X - \bar{X})^2} \times \sqrt{\sum (Y - \bar{Y})^2}}$$


Le coefficient de corrélation est compris entre -1 et $+1$.

Plus il s'éloigne de zéro, meilleure est la corrélation.

$r = +1$ corrélation positive parfaite
 $r = -1$ corrélation négative parfaite
 $r = 0$ absence totale de corrélation

Quelques exemples de corrélation

(le coefficient de corrélation r est indiqué dans chaque cas)



Exemples:

- Supposons un échantillon aléatoire de 4 firmes pharmaceutiques présentant les dépenses de recherche X et les profits Y suivants (en millions de dollars)

X	Y
-----	-----

40	50
40	60
30	40
50	50

- Trouvez la droite de régression et le coefficient de corrélation.

Calculons tout d'abord $\bar{X}$ et $\bar{Y}$

$$\sum d^2 = \text{minimum}$$

$$Y = a.X + b$$

- Complétons le tableau suivant:

X	Y	$X - \bar{X}$	$Y - \bar{Y}$	$(X - \bar{X})^2$	$(Y - \bar{Y})^2$	$(X - \bar{X}) \cdot (Y - \bar{Y})$
40	50	0	0	0	0	0
40	60	0	+10	0	+100	0
30	40	-10	-10	+100	+100	+100
50	50	+10	0	+100	0	0

- On a donc:

$$\sum (X - \bar{X})^2 = 200$$

$$\sum (Y - \bar{Y})^2 = 200$$

$$\sum (X - \bar{X}) \cdot (Y - \bar{Y}) = 100$$

- Les coefficients de la droite de régression sont:

$$a = \frac{\sum (X - \bar{X}) \cdot (Y - \bar{Y})}{\sum (X - \bar{X})^2} = \frac{100}{200} = 0,5$$


$$b = \bar{Y} - a.\bar{X} = 50 - 0,5 \times 40 = 50 - 20 = 30$$

- Et le coefficient de corrélation:

$$r = \frac{\sum (X - \bar{X}) \cdot (Y - \bar{Y})}{\sqrt{\sum (X - \bar{X})^2} \times \sqrt{\sum (Y - \bar{Y})^2}} = \frac{100}{\sqrt{200} \times \sqrt{200}}$$

$$= \frac{100}{200} = 0,5$$

- La corrélation est **positive** et de **qualité moyenne**



- La corrélation entre la taille (X) et le poids (Y) pour les garçons de 2^{ème} candi. commu. donne les résultats suivants:

(a) droite de régression: $Y = aX + b$

$$a = 0,816 \quad b = -77,0$$

(b) coefficient de corrélation

$$r = 0,61$$

- La corrélation est donc **positive**, de **qualité moyenne**

- De la même manière, pour les filles, on obtient:

(a) droite de régression: $Y = aX + b$

$$a = 0,239 \quad b = 16,6$$

(b) coefficient de corrélation

$$r = 0,20$$

- La corrélation est **positive** (les filles les plus grandes tendent à être les plus lourdes), mais de **très mauvaise qualité** (r proche de zéro).

Remarques:

- Le coefficient de corrélation nous donne des informations sur l'existence d'une relation **linéaire** (sous forme d'une droite) entre les deux grandeurs considérées.

Un coefficient de corrélation nul ne signifie pas l'absence de toute relation entre les deux grandeurs. Il peut exister une relation **non linéaire** entre elles.

(cf. exemple (f) ci-dessus: la connaissance de X nous donne des informations sur la valeur de Y).

- Il ne faut pas confondre **corrélation** et **relation causale**.

Une bonne corrélation entre deux grandeurs peut révéler une relation de cause à effet entre elles, mais pas nécessairement.

Exemples:

- Si on compare la durée de vie des individus à la quantité de médicaments pour le coeur qu'ils ont absorbée, on observera probablement une corrélation négative. Il serait imprudent de conclure que la prise de médicaments pour le coeur abrège la vie des individus (en fait, dans ce cas, la corrélation est l'indice d'une cause commune: la maladie de coeur).
- Le soleil tire son énergie de réactions nucléaires transformant l'hydrogène en hélium. Notre société tire une bonne part de son énergie de la combustion du pétrole. Si on compare, année après année, la quantité d'hélium contenue dans le soleil au prix moyen du pétrole, on obtiendra une bonne corrélation positive, sans qu'il y ait la moindre relation de cause à effet, ni aucune cause commune.
- Depuis une dizaine d'années, la taille de mon fils cadet, né en 1989, est très bien corrélée avec la puissance de calcul des ordinateurs personnels. Cette excellente corrélation ne révèle bien évidemment aucune relation de cause à effet, ni cause commune.

L'existence d'une corrélation, aussi bonne soit elle, n'est jamais la preuve d'une relation de cause à effet.

ENSEIGNANT : Mohamed vall Zein